

Giulio Leone | Senior AI Engineer — Generative AI & Sistemi LLM

Roma, Italia

Disponibile al trasferimento UAE (Dubai / Abu Dhabi) — Disponibilità immediata

☎ +39 366 141 0914 • ✉ giulioleone097@gmail.com • 🌐 giulioleone.com

in giulioleone1 • 💬 WhatsApp / 📠 Telegram disponibile

Profilo Professionale

Senior AI Engineer con **7+ anni di esperienza** nella progettazione e deployment di sistemi di Intelligenza Artificiale Generativa in produzione. Specializzato in **architetture RAG, Agentic AI, Generative UI** e integrazione enterprise di LLM. Solida capacità Full-Stack (Python, React/Next.js) per lo sviluppo end-to-end di prodotti AI — dall'orchestrazione dei modelli all'interfaccia utente. **66+ certificazioni tecniche** tra cui AWS, Microsoft Azure, Google, Oracle, IBM, MongoDB e Neo4j. Laurea Magistrale in Ingegneria Gestionale (Trasformazione Digitale) con tesi su Generative UI e sistemi RAG embedding-free.

Esperienza Professionale

Attività Indipendente — 15+ Progetti Consegnati

Roma, Italia

Senior AI Engineer & Consulente Tecnico

Gen 2020 – Presente

Responsabile tecnico per architettura AI e implementazione full-stack su progetti per aziende medio-grandi. Coordinamento di team cross-funzionali di 2–5 ingegneri. Portfolio clienti: **FinTech Tier-1 europea** (500K+ utenti), **piattaforme E-commerce mid-size** e **produttori IoT industriale**.

- **Agentic AI & Generative UI:** Progettata un'OmniApp multi-agente con agenti AI autonomi e Generative UI, rendering di componenti React in tempo reale tramite orchestrazione LLM (LangChain, Vercel AI SDK). Gestione fallback, streaming e tool-use patterns. **Riduzione del 40% dei tempi di sviluppo UI.**
- **Sistemi RAG Enterprise:** Progettati e deployati pipeline RAG ibride (ricerca vettoriale + BM25 + disambiguazione iterativa) su 50K+ documenti per knowledge base aziendali. **Riduzione del 30% del tasso di allucinazioni** nei chatbot customer-facing.
- **Piattaforme Full-Stack:** Realizzate 5+ dashboard aziendali (React, Redux, Context API) con backend ad alte prestazioni (Python FastAPI, Django). **Latenza P95 sotto 800ms** tramite caching Redis e ottimizzazione CDN.
- **Modernizzazione Legacy:** Guidata migrazione COBOL-to-Python di circa 50K righe di codice utilizzando workflow di traduzione AI-assistita. **Velocità di riscrittura migliorata del 60%.**
- **Sviluppo AI-Augmented:** Integrazione di assistenti AI nel workflow quotidiano per sviluppo, debugging, code review e generazione automatica di test, accelerando significativamente i cicli di delivery.
- **Cloud & DevOps:** Pipeline CI/CD (GitHub Actions), deployment containerizzati (Docker, Kubernetes), infrastruttura cloud su Azure e AWS. Standard di sicurezza OWASP.

Freelance

Roma, Italia

Full-Stack Developer

2018 – 2019

Inizio carriera costruendo applicazioni web e consegnando soluzioni end-to-end per clienti small business.

- Realizzati 8+ progetti per clienti: applicazioni web responsive (JavaScript, HTML/CSS, PHP), REST API (Node.js) e backend database-driven (MySQL, PostgreSQL).
- Gestione dell'intero ciclo di vita dei progetti, dalla raccolta requisiti al deployment e manutenzione.
- Sviluppate solide competenze in architettura software e comunicazione con il cliente, che hanno permesso la transizione verso l'AI engineering.

Progetti AI Chiave

OmniApp — Piattaforma Generative UI: Sistema multi-agente che renderizza interfacce React dinamiche in tempo reale tramite orchestrazione LLM. Stack: Next.js, Vercel AI SDK, LangChain. **40% più veloce** rispetto allo sviluppo tradizionale.

Engine RAG Enterprise: Sistema di ricerca semantica e Q&A su 50K+ documenti aziendali. Retrieval ibrido vettoriale + BM25 con disambiguazione iterativa. Stack: Pinecone, ChromaDB, Python. **+30% accuratezza nelle risposte.**

Dashboard IoT Industriale: Piattaforma di monitoraggio real-time per dati sensoristici industriali.
Stack: React, FastAPI, WebSocket, TimescaleDB. **10K+ data points/sec** con latenza sotto 200ms.

Competenze Tecniche

AI & GenAI: Integrazione LLM (OpenAI, Anthropic, Cohere), LangChain, LangGraph, Vercel AI SDK, RAG (Vettoriale + BM25 Ibrido), Agentic AI, CrewAI, Generative UI, Prompt Engineering, LLMOps, AI Evaluation & Guardrails

ML & Data: Python, Pandas, NumPy, Scikit-learn, Keras, Pinecone, ChromaDB, Neo4j

Full-Stack: React / Next.js, TypeScript, Angular, Vue.js, Tailwind CSS, Django, FastAPI, Node.js, Express, GraphQL, REST

Cloud & DevOps: AWS, Microsoft Azure, Docker, Kubernetes, GitHub Actions, Terraform, CI/CD

Database: PostgreSQL, MongoDB, Pinecone, ChromaDB, Neo4j, TimescaleDB, Redis

Istruzione

Università Unimercuratorum

Laurea Magistrale in Ingegneria Gestionale — Trasformazione Digitale, Media: 27/30 — Completamento previsto, no

- **Tesi:** Framework per Generative UI e RAG embedding-free — riduzione costi computazionali e latenza nei sistemi AI enterprise.
- **Ricerca:** 2 paper sottomessi a riviste internazionali peer-reviewed.

Università Niccolò Cusano

Italia

Laurea Triennale in Ingegneria Gestionale (L-9)

2018 – 2021

Tesi sull'applicazione del machine learning: algoritmo K-Nearest Neighbors (KNN) per task di classificazione.

Certificazioni (Selezione da 66+)

AI & GenAI: AWS Certified Generative AI Developer – Professional · Microsoft Azure AI Engineer · Oracle OCI Generative AI Professional · IBM Multimodal GenAI Apps · Oracle AI Agent Studio

Data & ML: IBM Data Science Professional · Oracle OCI Data Science Professional · Neo4j Graph Data Science · Google Data Analytics

Database: MongoDB Associate Developer · Oracle AI Vector Search Professional · Neo4j Certified Professional

Security: Google Cybersecurity Professional · Microsoft Security Foundations · Oracle OCI Foundations

Lista completa delle 66+ certificazioni disponibile su: github.com/giulio-leone/cv

Lingue

Italiano: Madrelingua

Inglese: C1 — Avanzato

Uso professionale quotidiano in progetti internazionali